社内データベースから自動的な異常検知について

観測できない潜在情報を積極利用した自動アノマリー検出

山口 学

安全管理部

2016/08

CURRENT section

1. 異常検知 (anomaly detection) する道具の提案
2. 異常検知と自動識別の枠組み
3. パラメータ推定法
4. まとめ
5. Appendix

どのようなデータを分析対象にしたか？

安全性自発報告のシステム (CW5 と通称。以下 DB) から期間を設定。情報源を「自発報告」とし、因果関係、重篤性、未知など制限を加えない[1] 。

- DB の主な取扱い

情報抽出期間	最新 8 年と設定
index1	「第一報情報入手日」を月単位でグルーピング
index2	薬剤 CODE（入力そのまま）をグルーピング
index3	有害事象名を MedDra 用語 PT 単位でグルーピング

[1]本文で展開する時系列分析では、文献情報等のモデル化は困難であり除外

従来の情報の見方・その改善

従来の情報の見方

1. 条件抽出した一覧表やその単純集計
2. 閾値、すなわち「**定数**」の利用。
   - 2.1 未知症例が、（閾値）XX 例したら・・・
   - 2.2 重篤例が（閾値）XX 例したら・・・

```
# A tibble: 2 x 4
  YEARMON   CODE                      PT  YOBS
   <fctr> <fctr>                  <fctr> <int>
1 2013_06    FBX アナフィラキシーショック     1
2 2013_03    FBX アナフィラキシーショック     1
```

単純一覧表には、情報処理上の問題がある I

一覧表形式は経時変化が把握しにくい

DB 抽出は存在するもののみを一覧化。「0」情報が「情報落ち」する。
「0」情報が無いと時系列分析に制限が加わる。

1. 稀な有害事象における「情報落ち」が特に大きいので・・・
   - 1.1 「全 DB 中 XXX 件」など、一律な**定数**による判断
   - 1.2 「平均 XX 例」などの現状把握が困難
   - 1.3 将来の発生見積もりが KKD
2. 基礎統計値（平均、分散など）が正しく得られないので・・・
   - 2.1 分母の情報が欠落

XX 件発生・・・が多いか少ないか？ という客観性評価が困難

報告数のみを利用すると**過大・過少評価の恐れ！**

単純一覧表には、情報処理上の問題がある II

「0」の出力・その他情報の整備

多くの情報システムが持つ、「共通の弱点」を改善

1. 基礎統計値（平均、分散など）が得られる
2. 母数が得られる
   - 2.1 **確率モデル**による**期待値**が得られる
   - 2.2 確率を利用した客観的な anomary detection
3. 自然な情報処理で正しく結果を導ける
   - 3.1 自由に誰もが情報処理・要約できる
   - 3.2 技能不要で経時的変化の把握ができる
   - 3.3 グラフ化して解釈しやすい

データ構造を工夫すれば、多くの情報が得られる！

利用した database の構造

代表的データ構造の列名称・内容

- YEARMON
  - 20080901 から 20160831 までの 96 か月で、時点"2008_01"などを示す
- YOBS
  - 当該月に報告された件数。有害事象と薬剤組み合わせ単位
  - 「0」情報を含む
- ICSRS_MONTH
  - 当該月に報告された、薬剤その全部の数。報告率算出用
- MASS
  - DB 中に月単位で何月報告されたか [a]（96 か月の場合,0〜96）
- CODE
  - 社内の医薬品分類コード（英字 3 or 4 文字）
- PT
  - MedDRA の PT 和名
- BETA
  - 対象 DB に保存されている「ある薬剤の総レコード数」（期間内全合計数）

[a] 命名田崎

利用した database の概要

代表的な列の単純集計

- 薬剤 CODE domain 濃度
  - 176 件
- PT domain 濃度
  - 1404 件
- 薬剤 × PT 組わせ

  理論的組み合わせ 247104 組
  存在する組み合わせ 6905 組（0%）

例えば FBX の光線過敏性反応は報告事例がない。

```
> dbsql %>% filter(CODE == "FBX", PT == "光線過敏性反応")
# A tibble: 0 x 14
# ... with 14 variables: YEARMON <fctr>, CODE <fctr>, SOC <fctr>, PT <fctr>, YOBS <int>, ICSRS <int>,
#   ALPHA <int>, BETA <int>, ALPHA0 <int>, BETA0 <int>, RWNUM <int>, MASS <int>, PT_MASS <int>, DRUG_MASS <int>
```

存在割合は 0%と情報粗密行列の状態だった。

0 例も把握できる良いデータ構造の利用

FBX アナフィラキシーショック

```
> getYobsData(code = "FBX", pt = "アナフィラキシーショック")
# A tibble: 96 x 7
   YEARMON  YOBS ICSRS  MASS   CODE                      PT  BETA
    <fctr> <dbl> <dbl> <int> <fctr>                  <fctr> <int>
 1 2009_08     0     0     2    FBX アナフィラキシーショック   640
 2 2009_09     0     0     2    FBX アナフィラキシーショック   640
 3 2009_10     0     0     2    FBX アナフィラキシーショック   640
 4 2009_11     0     0     2    FBX アナフィラキシーショック   640
 5 2009_12     0     0     2    FBX アナフィラキシーショック   640
 6 2010_01     0     0     2    FBX アナフィラキシーショック   640
 7 2010_02     0     0     2    FBX アナフィラキシーショック   640
 8 2010_03     0     0     2    FBX アナフィラキシーショック   640
 9 2010_04     0     0     2    FBX アナフィラキシーショック   640
10 2010_05     0     0     2    FBX アナフィラキシーショック   640
# ... with 86 more rows
```

確率モデルが使いやすい組み合わせ I

「報告」という事象を巧く説明するモデルとしてポアソン分布がある。

還元論的に、有害事象「報告」もこの法則に従うと考えるのが自然。
ポアソン分布は、母数を λ とした時、事象 X の確率，期待値、分散、累積分布関数はそれぞれ下記に従う [**masuo**]。

$$
\begin{aligned}
Pr(X = x \mid \lambda) &= \frac{\lambda^x}{x!} e^{-\lambda} \qquad (x = 0, 1, 2, \cdots, \infty) && (1)\\
E[X] &= \lambda \\
V[X] &= \lambda \\
CDF(k) &= e^{-\lambda} \textstyle\sum_{i=0}^{k} \frac{\lambda^i}{i!} && (2)\\
& && (3)
\end{aligned}
$$

ポアソン分布に従う事象は、母数，期待値、分散が等しいことが要請される。

これを実データで確認し、利用する。

確率モデルが使いやすい組み合わせ II

FMXA の薬疹報告を取り上げる。

```
> (dat <- getYobsData(code = "FMXA", pt = "薬疹") %>% select(YEARMON, YOBS))

# A tibble: 96 x 2
   YEARMON  YOBS
    <fctr> <dbl>
 1 2009_08     2
 2 2009_09     0
 3 2009_10     1
 4 2009_11     0
 5 2009_12     0
 6 2010_01     1
 7 2010_02     0
 8 2010_03     0
 9 2010_04     1
10 2010_05     0
# ... with 86 more rows

> dat$YOBS

 [1] 2 0 1 0 0 1 0 0 1 0 0 2 2 0 0 0 0 0 0 1 0 0 0 1 1 2 0 1 1 0 0 0 0 0 0 1 0 0 0 0 0 1 0 2 1 0 2 1 0 0 0 2 2 0
[55] 1 1 1 1 0 0 0 1 0 0 0 1 0 0 0 0 1 0 1 0 0 0 0 0 0 1 1 1 0 0 0 0 2 0 0 0 0 2 0 0 0 1
```

報告数をクロス集計し、度数ごとの経験確率と標本平均を母数とした時のポアソン分布との適合度を図示する。
この方法は、[**alan**], [**Friendly**] らによる goodfit test for Poisson Distribution と呼ばれる。

GoodFit test for Poisson Distribution

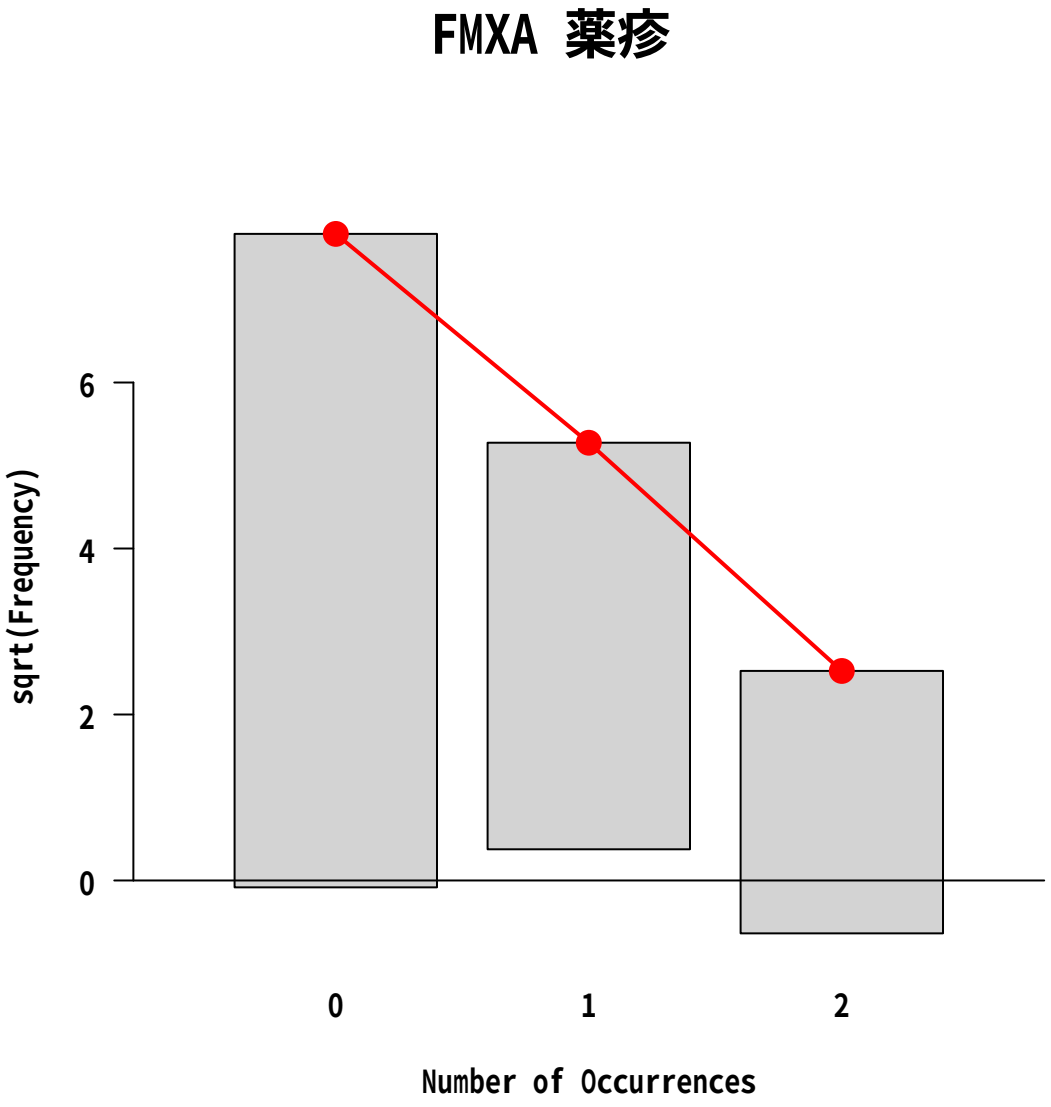

ポアソン分布にフィットすると何がよいか

ポアソン分布の性質は期待値=分散であった (P.10)。FMXA の薬疹データの月単位の平均報告数と分散を算出すると、データも平均値 ≃ 分散だった。

```
> mean(dat$YOBS)
[1] 0.458
> mean(dat$YOBS^2) - mean(dat$YOBS)^2
[1] 0.457
> mean(dat$YOBS)/(mean(dat$YOBS^2) - mean(dat$YOBS)^2)
[1] 1
```

「報告事象はポアソン分布に従う」ことが原理上分かっている。FMX 事例もポアソン分布に従っているとして問題がない。
加えて、「過去と状況が同じ限り、**今後も同様に発生する**」と考えるのが自然。

DB 中の全データに対して月報告平均と分散の比を評価し、ポアソン分布適合性を確認する。適合するデータに対しては、式 (1) より発生確率を得られる。
これにより、**「報告数を確率的に評価できる」**ので異常検知が自動化できる。

母数推定に十分な情報量を持つか？ I

6905 組全てについて母数推定に十分な情報量を持つかを調べた。

通常、頻度論アプローチによる推定では観察回数 MASS が最低 6 必用といわれる。母数推定には 30 以上が必要といわれる。

```
> dat <- dbsql %>% select(PT, CODE, MASS) %>% group_by(PT, CODE, MASS) %>% unique()
> dat6 <- (dat$MASS > 6)
> dat6 %>% table() %>% prop.table() * 100

.
FALSE  TRUE
92.14  7.86

> dat30 <- (dat$MASS > 30)
> dat30 %>% table() %>% prop.table() * 100

.
FALSE  TRUE
98.99  1.01
```

結果は $MASS > 6$ が 7.9%、$MASS > 30$ が 1%だった。
極めて少ないといえる。

母数推定に十分な情報量を持つか？ II

情報理論的アプローチを取った場合、母数推定には、MASS $>$ 3 若しくは単位月あたり報告数 ALPHA $>$ 3 が母数推定に最低限必用と考えられる。

```
> dat <- dbsql %>% select(PT, CODE, MASS, YOBS) %>% group_by(PT, CODE, MASS) %>% summarize(MAX = max(YOBS))
> dat <- dat$MASS > 3 | dat$MAX > 3
> dat %>% table()

.
FALSE  TRUE
 5868  1037

> dat %>% table() %>% prop.table() * 100

.
FALSE  TRUE
   85    15
```

	稀少情報な郡	母数推定可能な郡
割合	5868（85%）	1037（15%）

Table: 情報量による郡わけ

情報理論アプローチを取り、15% に対して母数推定する。確率を利用した各月発生数の評価を客観化できる。

重要ポイント

稀少な情報郡：カテゴリー０は自発報告全体の内、85 %だった。
これらは「未知」と見做せる低い発生確率と解釈できる。 「未知」と見做せる低い発生確率の場合に於いてのみ、3 例ルールは機能する。

現行手順の中で、数理理論的な対象外は正そう！

未知と見做せない残りの約 15%には、「定数」が使えない。 確率論が必用になる。
しかし、現在は一律定数。使えない基準を利用するが故に「また XXX の YYY か・・・」という意見になる。

即ち、一律「**定数**」の運用では、全てのパターンには対応できない。
個別に **母数推定** を行い、個別に **確率** 評価すると良い。定数から脱却し個別に母数を評価したほうが合理的。

現行ルールが機能しないモノが 15% 程度存在している。
これが我々を 悩ませる 正体である。

どれぐらいがポアソン分布形状に従うか？ I

P. 15 で示したように母数推定の対象は 15%であると分かった[2]。

次に、P. 10 の (1) 式が利用できるか否かを $\frac{\text{分散}}{\text{平均}}$ 比で確認する必要がある。

この比を Gamma 分布では Shape 母数と呼び分布形状を決める因子の一つになる。理論的にポアソン分布は Shape 母数 = 1 となる。1 以上は過分散な分布形状を示し、1 以下を過少分散な分布形状を示す。

	過少分散	Poisson	過分散
割合	1038 (69.5%)	1 (0.1%)	454 (30.4%)

Table: Shape 母数による分類

過少分散には、先行研究よりゼロ修正ポアソン分布（ZMP）が利用できる [**iwasaki3**]。
過分散には、FDA が利用する負の二項分布や WHO の β 二項分布が利用できる。

[2]それ以外は、「正しい 3 例ルール」を適応すれば良い。母数推定は不要

確率モデルで何が出来るようになるか？

確率モデルにより、「月報告数が予測できる」、「異常検知できる」 とは、「来月に 2 件報告がある」と決定づける事ではない。
サイコロの出目は予測できないが、「1」が出る確率は把握できる。それから外れたら異常と認知できる。これが異常検知に利用できる。

異常検知への役立て方

月平均報告数 $\lambda = 2$ をデータから得た場合、

- 有意水準（1-α = 0.05）を設定する。
- P.10 の CMF 関数から 95%の確率は、「5 件以下」と分かる
- 5 件以下は「**異常判定保留**」として翌月を見る
- 6 件以上の発生は、（以前と同じでない事から）異常と見做す

パラメータをデータから求めれば、「1 例発生確率は XX%」、「2 例は YY%」と分かるので、累積して有意水準 95%までの発生は許容する。
「それを超えた」モノを機械的に抽出する。 これは逐次直接確率検定を行う事に該当。検定を用いた「異常検知」が客観的・機械的に実現できる。

この様に、**anomaly 異常**があれば、自動的に識別できる

課題の把握

上昇傾向を示す例・多峰性を示す例

- CYM の悪心（報告数上昇傾向）
- PRS の光線過敏症（多峰性）

他社先行研究 [**ZMPdai**] で、安全性情報はポアソン分布が利用できる事に加えて、ゼロ修正モデルによる推定が良い事を報告した [**PART2**]。

しかし、修正モデルは一般に単峰を示す対象にしか使えない。
一方、事例のように上昇傾向を示すモノや多峰性を示すモノが存在する。

全ての事象を説明できる万能モデルが、存在しない事は 21 世紀に証明されている[3] 。
我々はデータに合わせて妥当なモデルを選択するべきである。

[3] no-free-lunch theorem(NFLT「あらゆる問題で性能の良い汎用最適化戦略は理論上不可能であり、ある戦略が他の戦略より性能がよいのは、現に解こうとしている特定の問題に対して特殊化（専門化）されている場合のみである」)

Introduction 解決方法の紹介

下降傾向・上昇傾向を示すモノや、多峰性を示すものであっても、異常検知に役立つ・有用なツールが求められる。

（ある程度それを満たす）

機械的に 分析し、分類し、可視化 する方法を開発したので報告する。

CYM の悪心

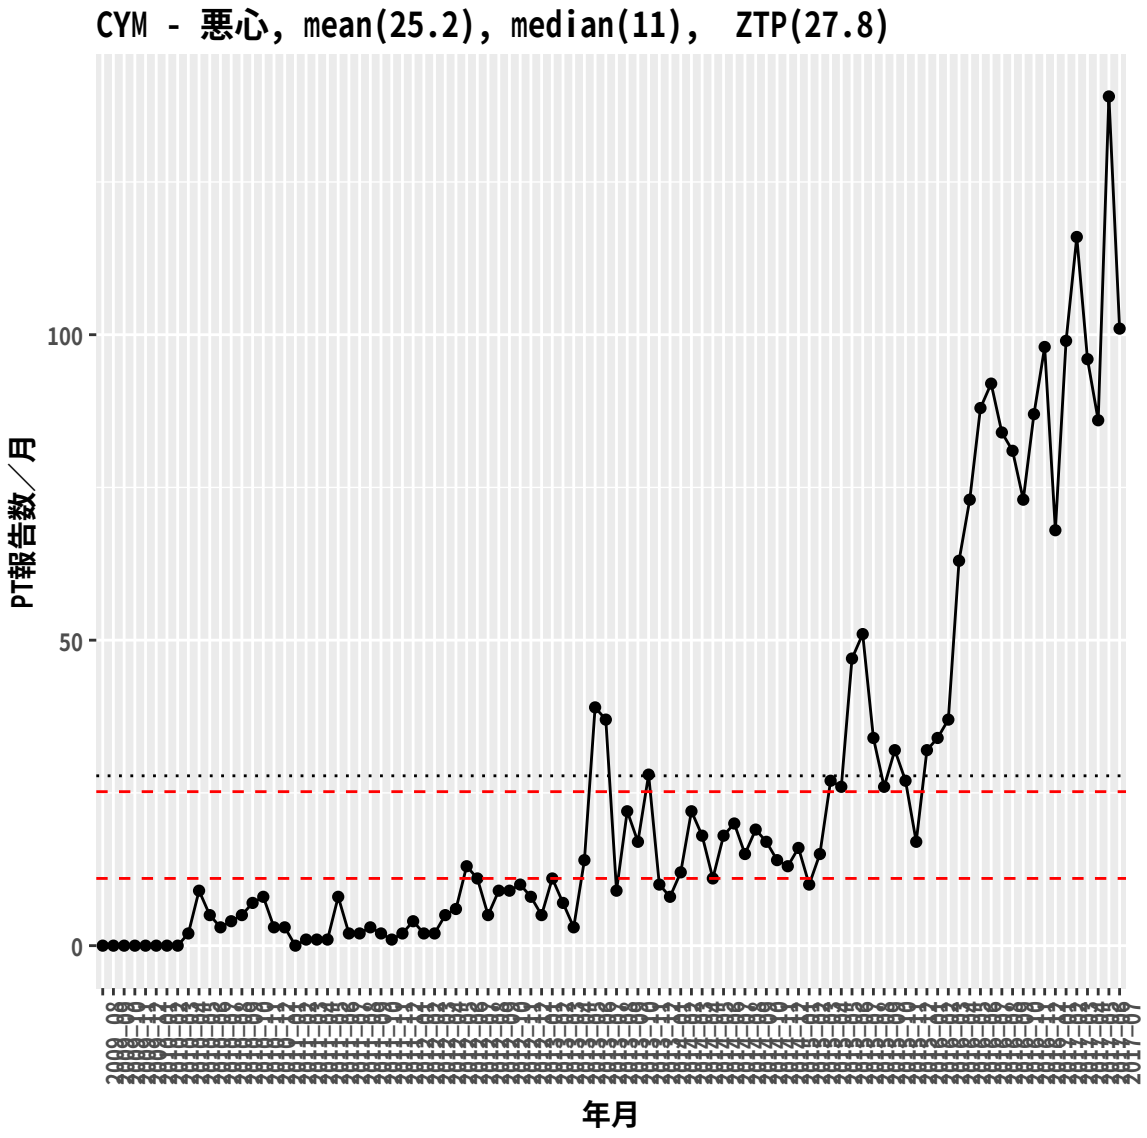

GoodFit test for Poisson Dist. CYM の悪心

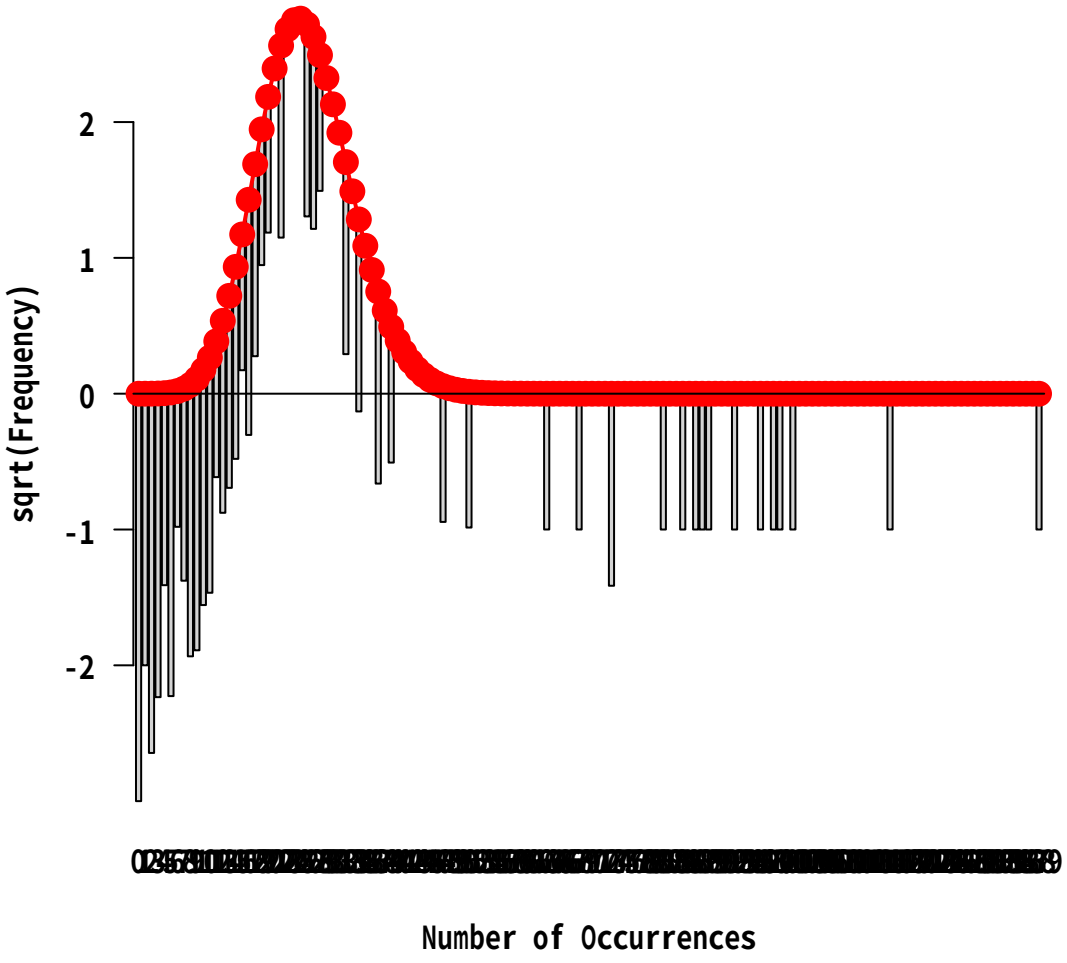

PRS の光線過敏性反応

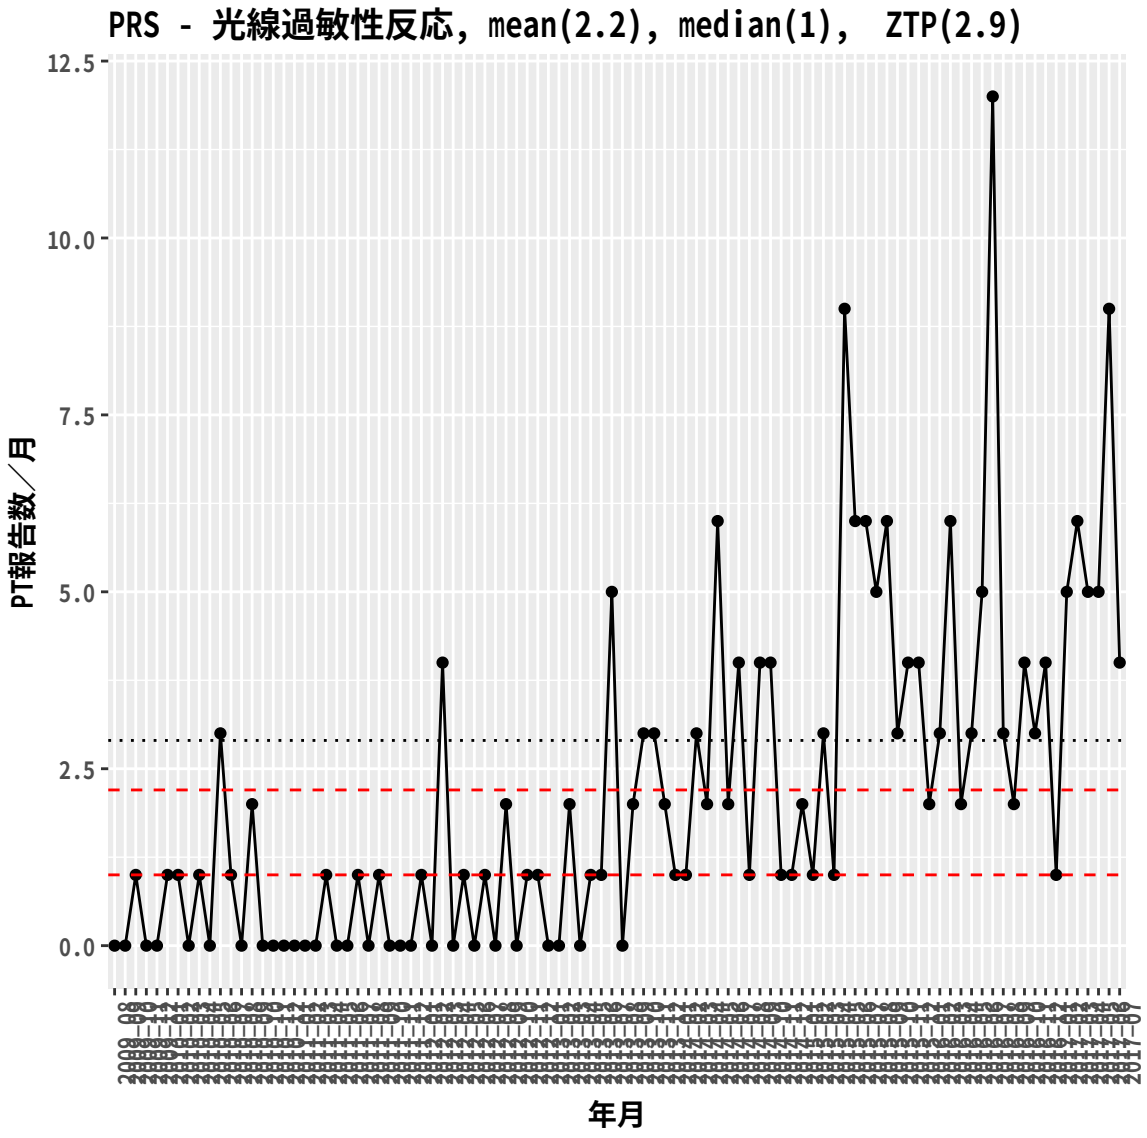

GoodFit test for Poisson Dist. PRS の光線過敏症

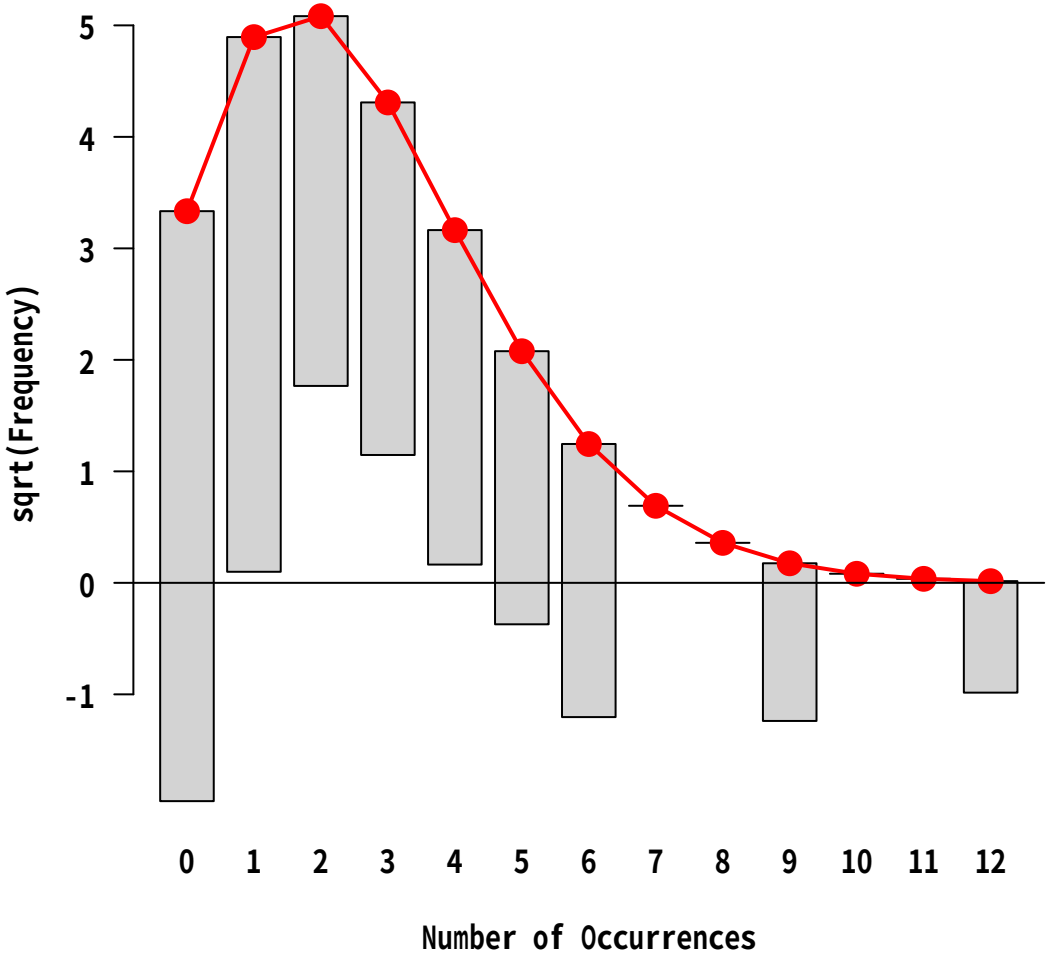

なぜあてはまり具合が悪いのか？

原因は、「平均」を代表として推論するには無理なデータ構造をしているため。

ある試行で「平均」で発生した事象は、別試行でも平均 ± バラツキで発生とするのは自然。また、データが大量に得られれば、「大数の弱法則」により必ず平均に収束する。

だが、前提に必用な仮定「独立・同分布、期間中の平均が一定 (i.i.d.) で大量データ」は、市販後では馴染まない。P.8 で示したように DB の情報量は、「疎」である。季節性も考慮が必用。

全ての期間中に有害事象の発生率が、「一定」という仮定もまた強すぎる。

変化が「存在するか」を見張る業務に、期間中「一定」を仮定するのは逆である。

説明困難な事例にどう対応するか？ I

混合モデルという同一分布が複数混合した場合を考えるのが尤も簡単。
「i.i.d 条件を満たさない事象」即ち複雑な事象を説明できるモデルとして利用できる。

潜在クラスモデル (Latent class model)

モデルの尤度関数は、左辺の $\boldsymbol{\theta}$ をパラメータベクトルとし、π を混合率、λ_1、λ_2 を分布固有パラメータとした時 (4) となる。

$$L(\boldsymbol{\theta}) = f(y \mid \boldsymbol{\theta}) = \prod_{i=1}^{n} \left\{ \pi \left(\frac{\lambda_1^{y_i}}{y_i!} e^{-\lambda_1} \right) + (1-\pi) \left(\frac{\lambda_2^{y_i}}{y_i!} e^{-\lambda_2} \right) \right\} \tag{4}$$

混合率情報は観測できない潜在情報であり、「潜在クラスモデル」と一般化される。

FDA シグナル指標 EBGM や WHO の BCPNN で既に利用されており我々に馴染み深い。有限混合分布モデル (finite mixture distributions model) とも言われる。
FDA、WHO を真似て、ある分布が２つ混合していると定義するのが自然であり、広くは計量経済でも利用される [**satomura**] 。

尤度関数 (4) のパラメータベクトル $\boldsymbol{\theta}$ を推定する。

説明困難な事例にどう対応するか？ II

潜在変数 π は背景にある分布個々のパラメータ λ_1、λ_2 を峻別する。このモデルは初等数学で解析解が得られない。 よって、数値計算法で推定することになる。

潜在クラスモデルの推定方法

- BFGS 法 [a] など反復法で最適解を推定
- EM Algorithm で最適解を推定 [b]
- マルコフ連鎖モンテカルロ法で最適解を推定 [c]
- (その他) モーメントからの線形代数で解く [d]
- (その他) グラフを書いて K.K.D[e]

[a] 準ニュートン法.1970 by Broyden, Fletcher, Goldfarb and Shanno
[b] 解説 PDF 参照
[c] Markov chain Monte Carlo methods simulation:MCMC の枠組みで MH 法,Gibbs 法等を利用
[d] 問題ごとに System equation が必用で高度
[e] Kan, Keiken and Dokyo

推定方法メリット・デメリット

利用できるパラメータ推定方法の中で、自動化の観点で優れた方法を選択する。各種推定の枠組みについては [**BModelonMixtureDist**] が詳しい。
尤も効率的と判断した EM algorithm(解説参照) による推定を利用した。P. 56 に基礎原理を記載する。

推定方法の Pros., Cons.

手法	メリット	デメリット
反復法	漸化式があれば、微分不要	結果が初期値に左右される
EM Algorithm	初期値不要で最適解が得られる	E-Step、M-Step の作成に難
MCMC Algorithm	乱数が定義出来れば何でも良い	莫大な計算資源、計算時間
モーメント法	線形代数の保証。高速処理可能	工学知識、データが大量に必要
KDD	机と鉛筆があれば推定できる	ヒトの感覚に依存

反復法は殆どの統計ソフトが対応。モデル、データ、初期値に関する知識が必要であり、大量・自動処理が一般に困難。

EM Algorithm は初期値に関わらず、反復毎に最適解に収束することが証明されている [**watanabe**]。
E-Step、M-Step は其々独立に推定できる特徴を持ち、新型 CPU での並列化も可能。MCMC に比べ 4-5 桁速い。効率的であり、自動化に良い。URL 資料参照
MCMC は乱数が定義できるモノは、全て推定可能で初期値問題も殆どない。
原理的に長時間計算が必用であり、今回行った計算時間は「**10 日**」。

PRS の具体例でパラメータを推定

P. 23 の PRS-光線過敏症のグラフに結果を重ねる。

「PRS ー光線過敏性反応」の推定結果

パラメータは推定結果は、それぞれ $\pi = 0.6$、$\lambda_1 = 0.7$、$\lambda_2 = 4.2$ となった。

- π は λ_1 の混合割合で、約 0.6 の期間で月平均 $\lambda_1 = 0.7$ と推定
- $1 - \pi$ は λ_2 の混合割合で、約 $1 - \pi$ の期間で月平均 $\lambda_2 = 4.2$ と推定

ビジネスマンにとって、数理の意味やプログラミング、エンジニアリングの価値より、 結果がどうかが気になる。

再掲：PRS-光線過敏症反応

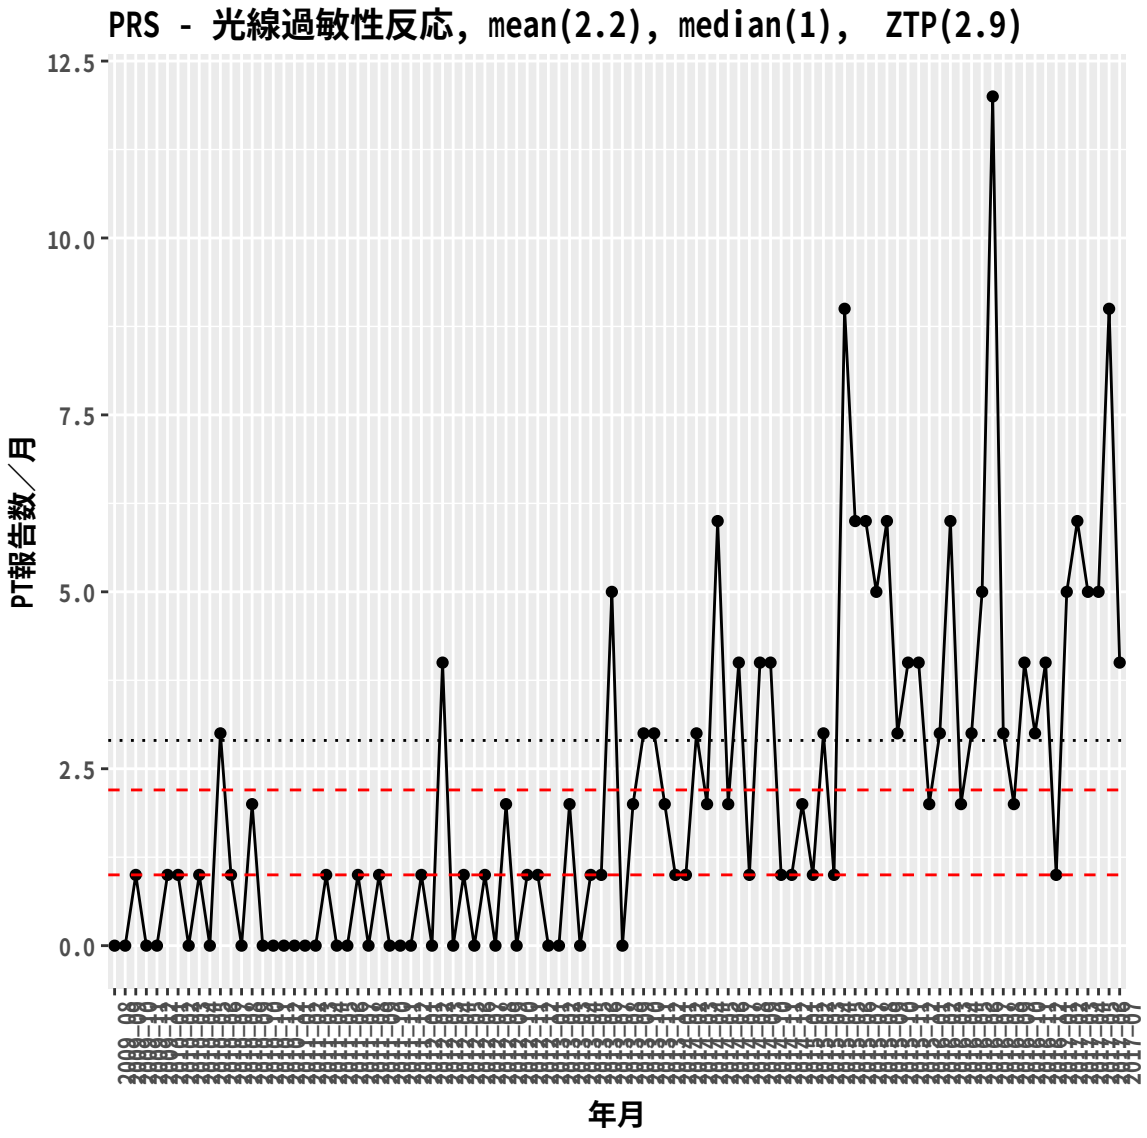

PRS ー光線過敏性反応の混合率推定

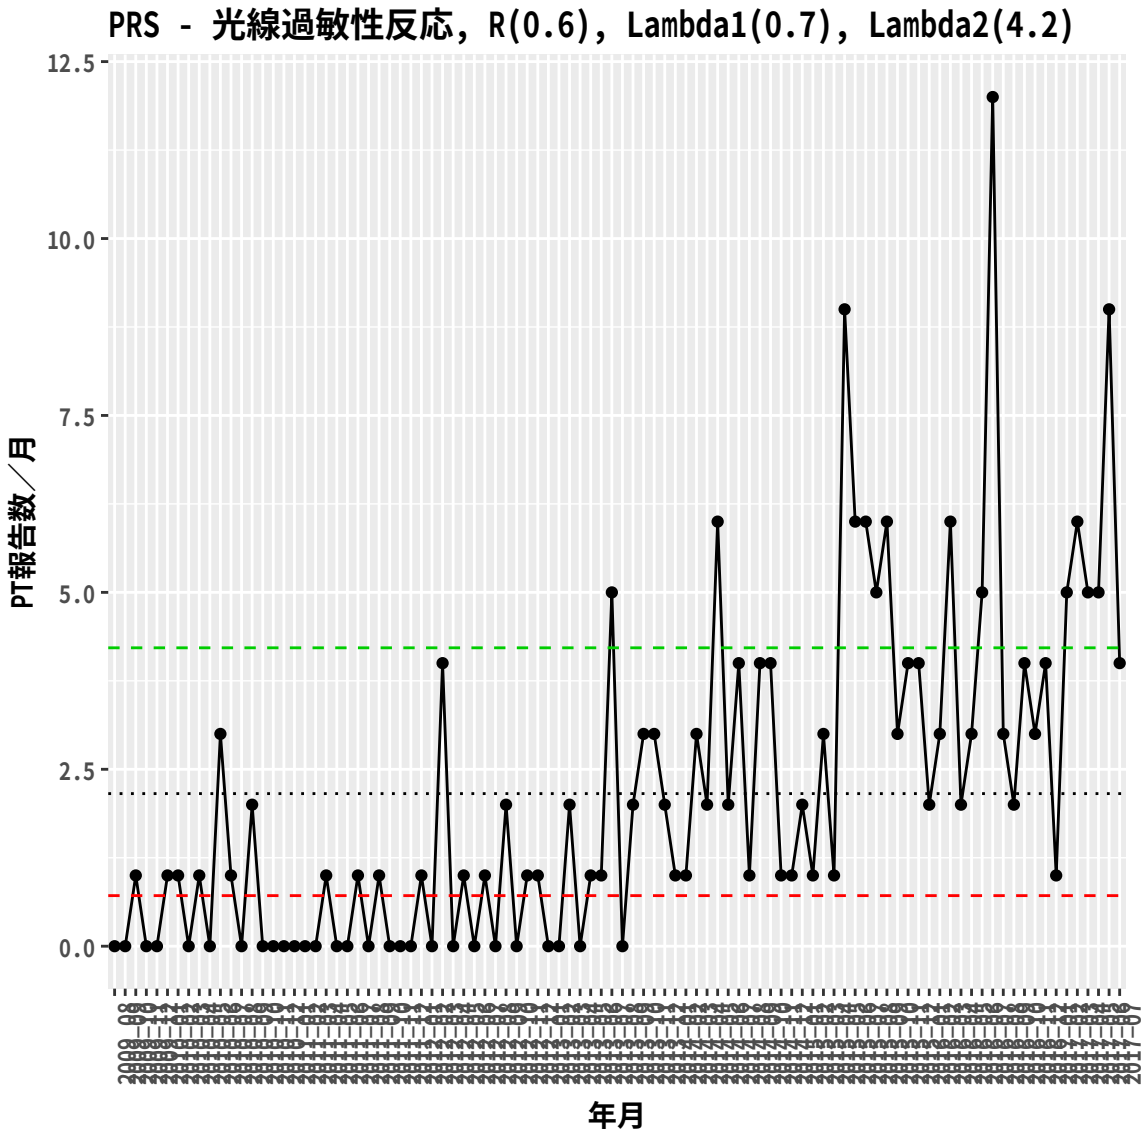

もう少し改良

P. 26 のモデル (4) 式の π は混合率を示す潜在パラメータであった。これを用いると有用な情報が得られる。

ベイズの定理を利用して事後確率を求めれば、 どちらに所属しているかを確率的に峻別できる。この峻別を機械学習では「クラスタリング」という。
P. 26 の式 (4) に所属情報 Zis を加えて書き直し、幾つかの数学的操作の後に次式を得る。

$$Class_s = \frac{\pi_s f_s(y_i \mid \lambda_i x)}{\sum_{j=1}^{2} \pi_j f_j(y_i \mid \lambda_\mathbf{j} x)} \tag{5}$$

(5) 式により、個別のデータ X の事後確率が得られる。判定は、「事後確率が ≥ 0.5 なら λ_1 の $Class_1$ に分類。それ以外なら λ_2 の $Class_2$ に分類。」と機械的に峻別できる。

専門知識を必要とせず、対象データから機械的にクラス分類するこの方法は、「教師なしデータ」の「クラスタリング（分類）」と呼ばれる。

PRS の光線過敏性反応の潜在モデル推定（横線）

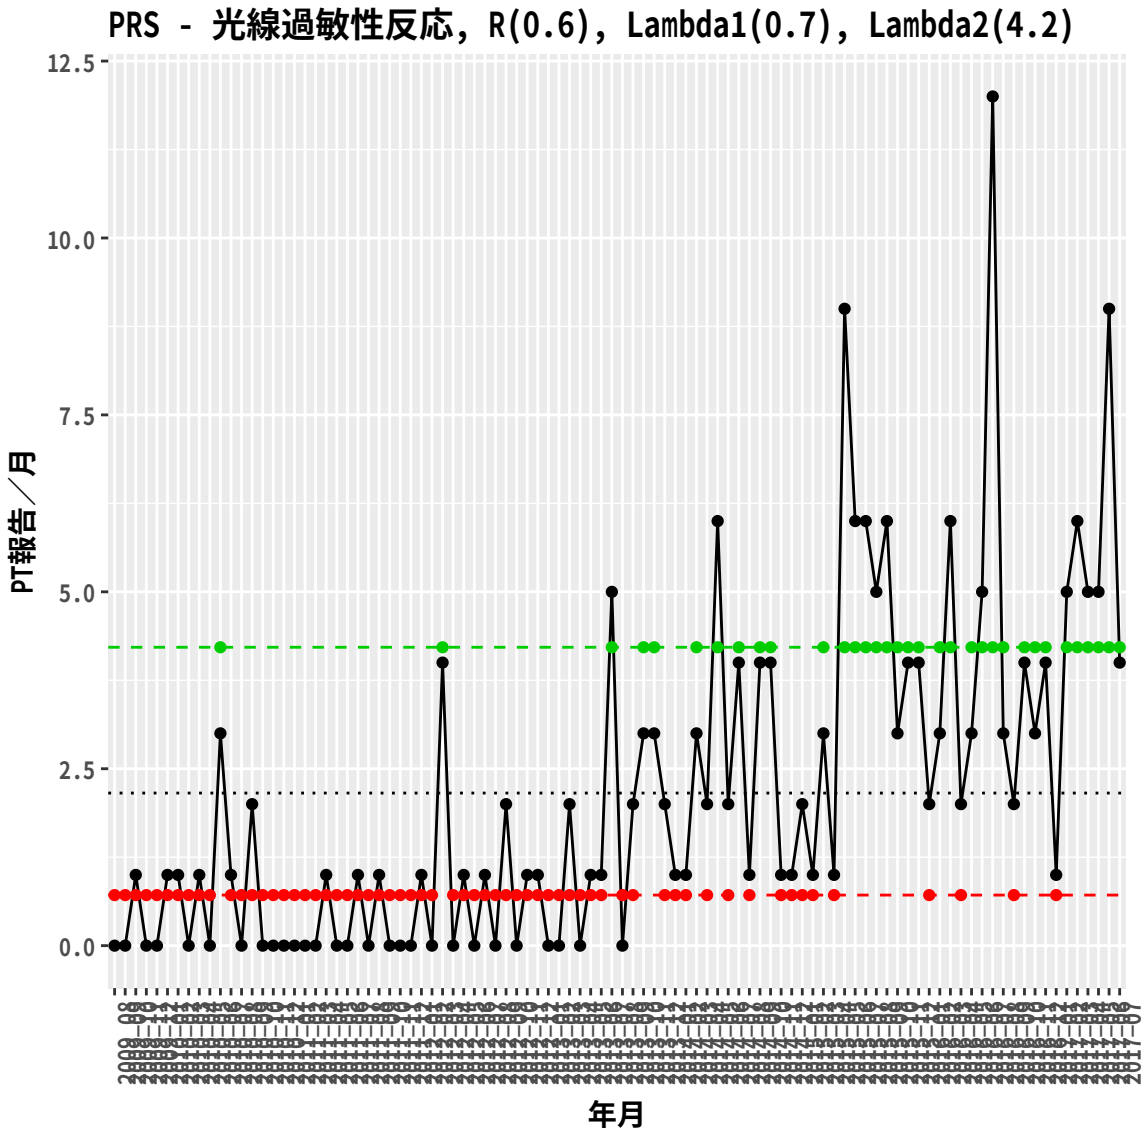

CYM の悪心、潜在モデル推定（横線）

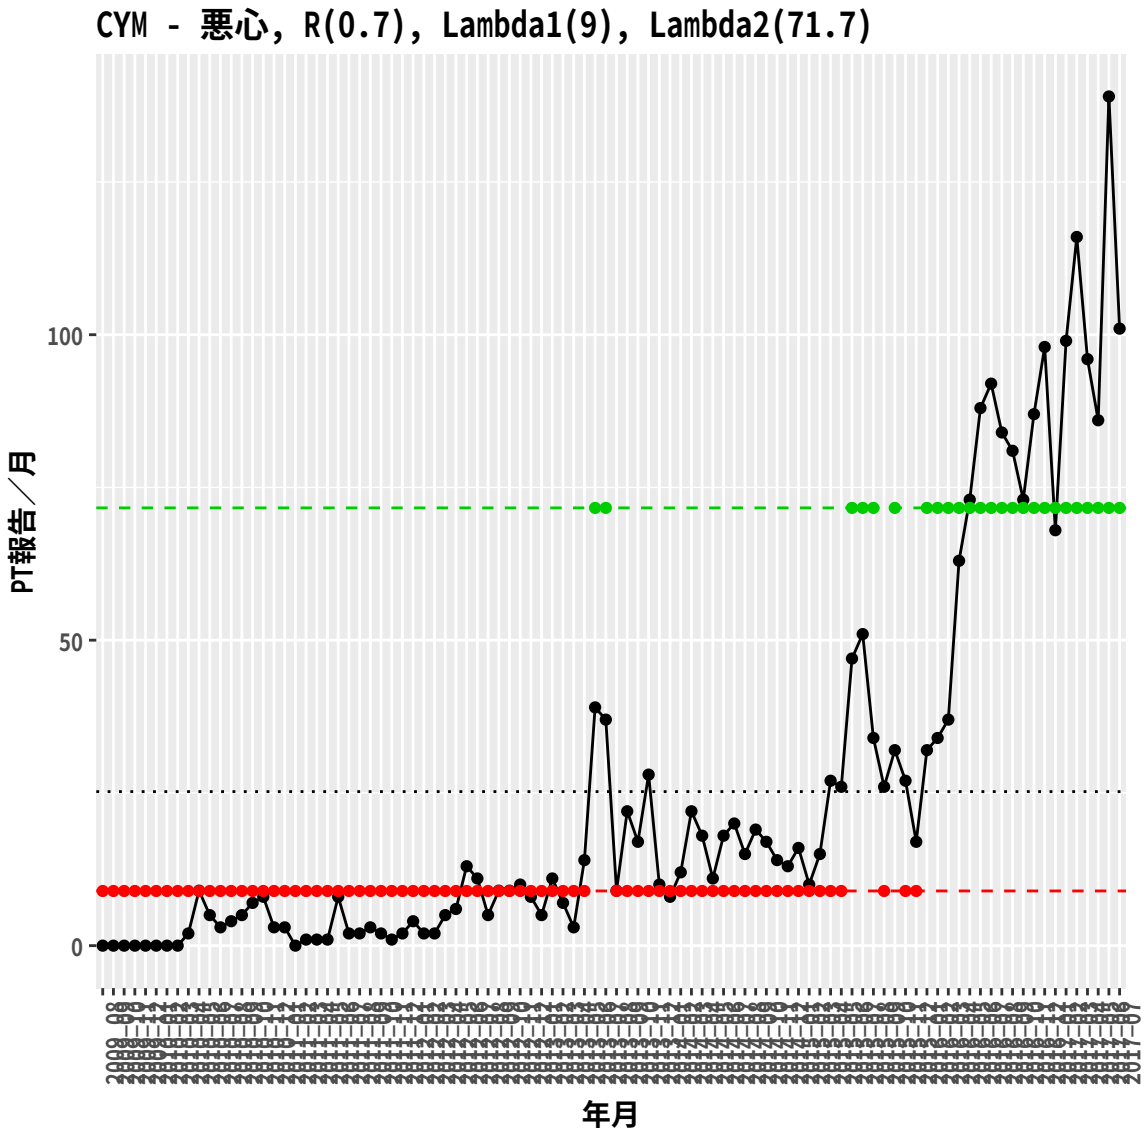

解釈例

異なる傾向が一目瞭然（ではなかろうか）。

PRS の光線過敏性反応

直後調査期間？ にある月ピークが存在。その後月平均 0.6 件に減少。
最近 1 年では月平均 4 件と発売初期に比べて約 6 倍の上昇。差は 3 例の上昇。

CYM の悪心

直後調査時？ に月平均約 6 件報告であった。この 2.3 年に上昇傾向が認められる。最近 1 年は平均約 47 件と発売初期に比べ、6 倍弱の上昇。差は 42 例上昇。

グラフだけでは読み取りにくい「変化点」を読み取れるので便利である。
しかし、「増加・減少傾向」を把握しにくい。

移動平均で平滑化し、**変動把握**を容易にする。 （最終提案までもうすこし）

PRS の光線過敏性反応（潜在クラスプロット）

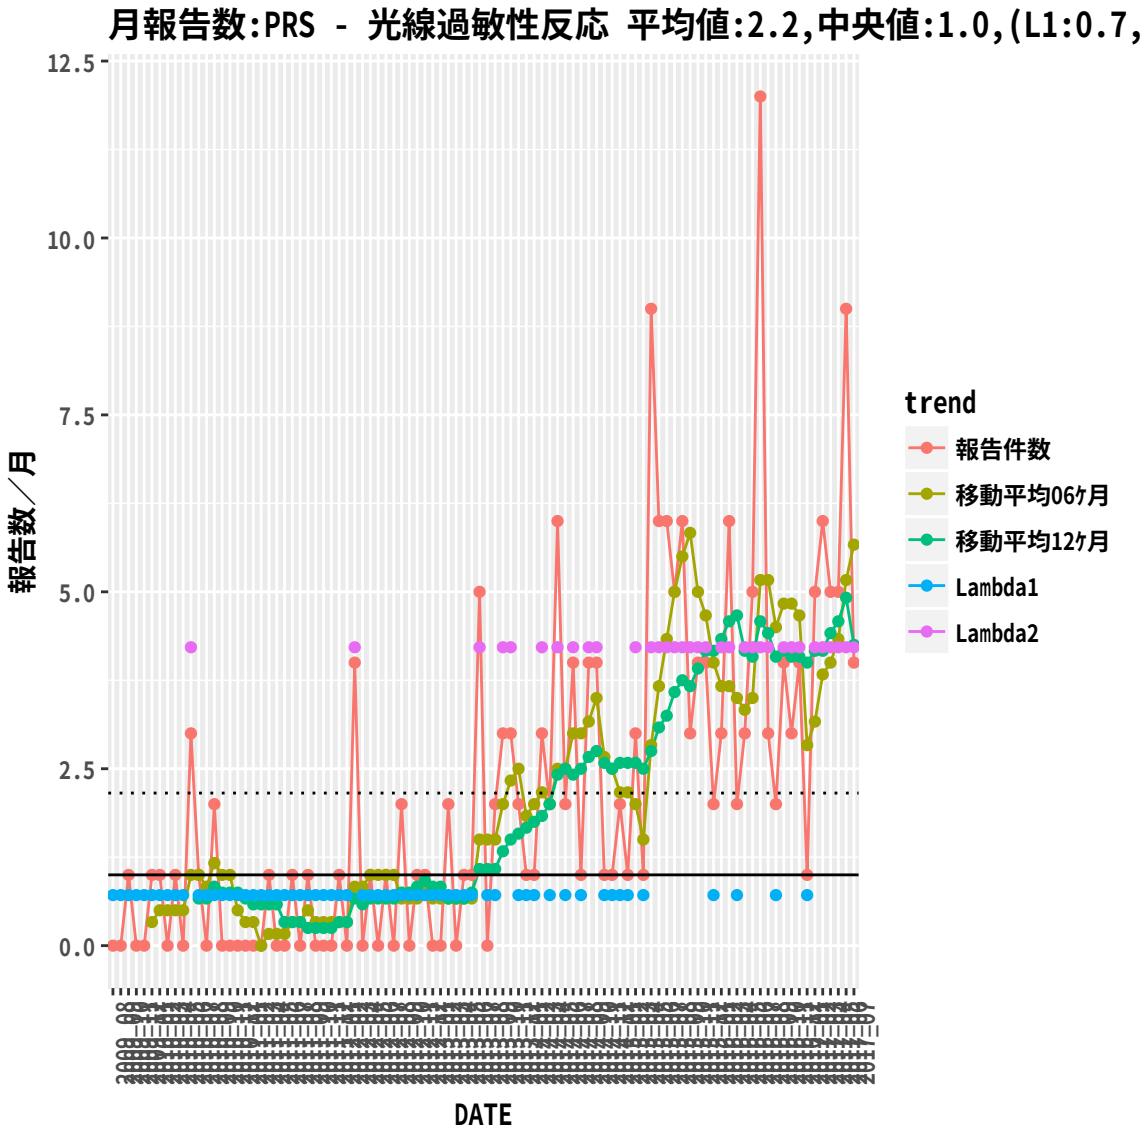

CYM の悪心（潜在クラスプロット）

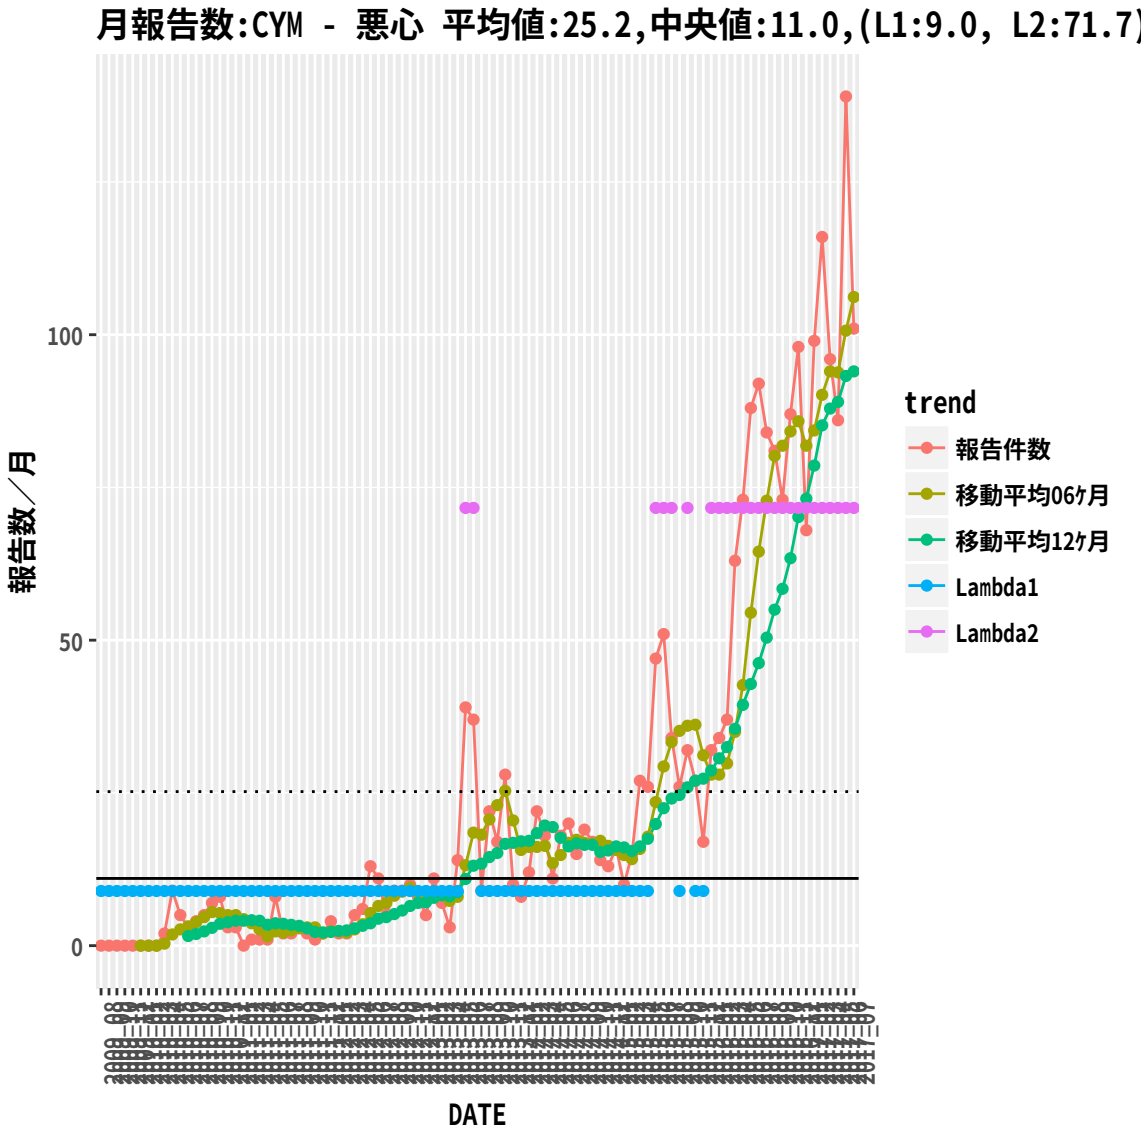

報告 PT の占拠率

有害事象の報告「数」の上昇が見られた場合、 効能追加などで薬剤自体の「**総報告数**」増加が主要因の場合がある。
有害事象の「**報告割合**」はその薬剤で不変だとしても、薬剤「**総報告数**」が増えると、「数」は **「見かけ上」**増加する。

$$\text{当該薬剤}\textbf{総報告数} \times \underline{\text{報告の割合期待値}} = \text{報告数}$$

この 報告の割合期待値 は全期間一定と仮定するのが自然。

$$\underline{\text{報告割合}} = \frac{\text{ある PT の報告数/月}}{\text{薬剤の全報告数/月}}$$

有害事象の月単位の「**報告割合**」を求め、パネルグラフを完成版として全品目で作成する。

グラフはこちらの Web で後悔

PRS-光線過敏性反応事例の完成版グラフ

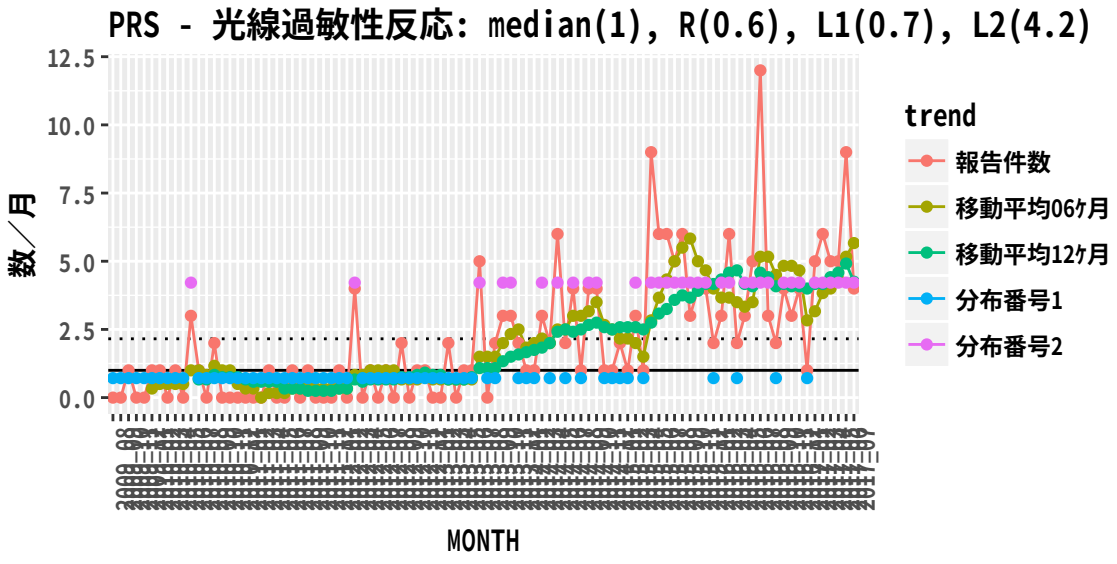

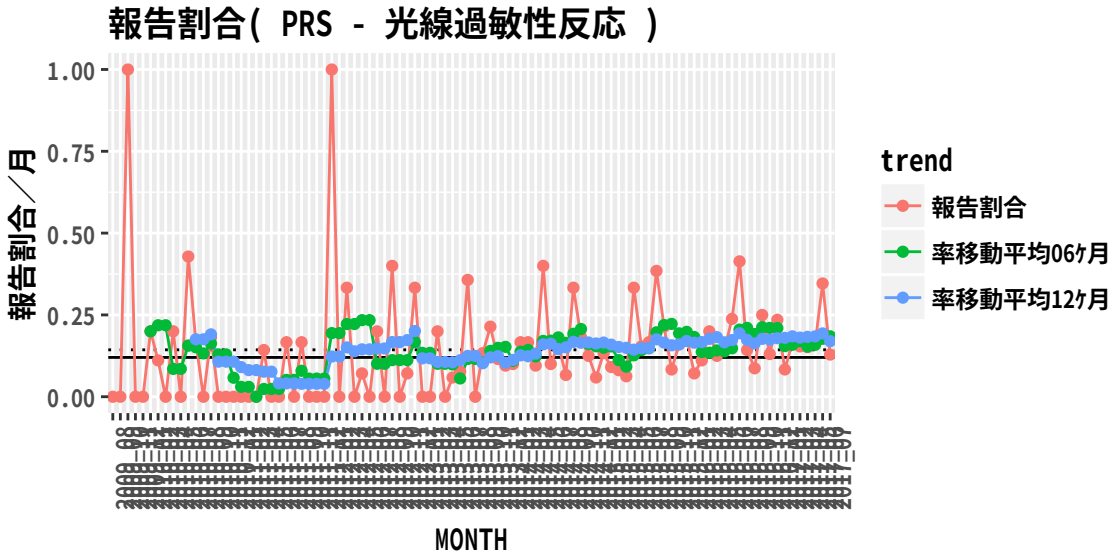

CYM-悪心事例の完成版グラフ

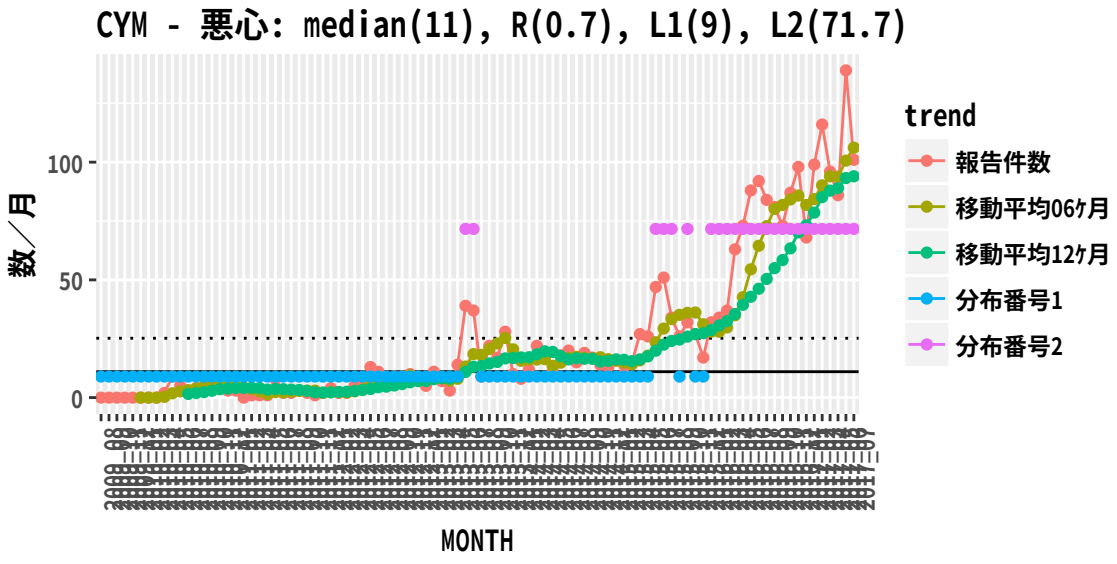

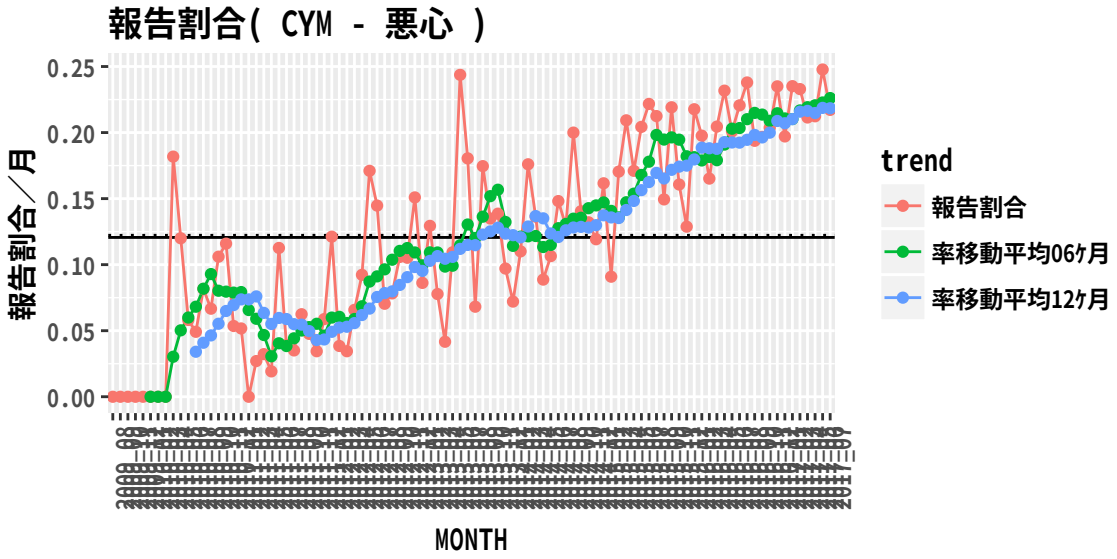

対策提案例

グラフを見て自然な解釈すれば、発生傾向の特徴をつかめるかもしれない。なぜそれが発生するのか？ などについての議論や、これからどうするかについて議論の材料にしていただきたい。

PRS の光線過敏性反応

他社類似品の上市もあり、再度光線過敏症についての対策について丁寧な情報提供が必用となる可能性もある。

CYM の悪心

重要な戦略品目に該当し、悪心など QOL を損なう事象の上昇傾向が投与・量の増加の抵抗になっている可能性がある。丁寧な情報提供などが必用かもしれない。

専門家にゆだねる。

CURRENT section

1. 異常検知 (anomaly detection) する道具の提案
2. 異常検知と自動識別の枠組み
3. パラメータ推定法
4. まとめ
5. Appendix

異常検知の枠組み 1

各種パラメータの算出と一覧化

- 基礎統計量（平均、分散、平均／分散比）
- ZTP モデルのパラメータ推定
- 潜在クラスモデルのパラメータ推定
- その他

あらかじめ全ての組み合わせを抽出し、計算し台帳化する。（こちらの Web に保管）

集計期間を適宜定め[4]、薬剤（濃度 176 種類）× PT（濃度 1404 種類）の組み合わせ中の、存在する組み合わせ全て (6905) に対して、上記を例に統計的フレームワークを適用して、台帳化する。

計算スケジュールは自由。逐次データ処理（毎日、毎週、毎月）可能

[4]現在は直近 8 年間（20090801 から 20170731）を設定

異常検知の枠組み２

閾値設定がいったん完了すれば、その後は機械的な情報処理が可能。機械的に全ての組み合わせについて網羅的にスキャンできる。

たとえば四半期に、すべてを確認するなど定めた期間で確認し続ければよい。「閾値」設定は協議して設定する必要がある。

多様なヒトを含めた検討により、感覚バイアスの影響があるかもしれない。そこで、近年専門知識を用いなくとも、情報エントロピーや多次元距離による類似度を用いた自動分類が確立している。これによる分類結果をまず提供する。

自動的にグループ分けし、ヒトの解釈を加え、再度分類を調整するサイクルにより、より完成度の高い自動検知プログラムを作成を目指す。このサイクルにより、**エキスパートシステム**の構築が可能になる。

(提案なのに未完）自動分類総説

仮題:CW5 計測分析の骨子

平均月報告数を分析して全体像を把握する

- ABC 分析
- 過大分散・過少分散の組み合わせざくっと把握
- Appendix：確率を用いる準備

(未完: 組み合わせ結果の構成図を作る）
CW5 の中身を全体的に把握する報告書を準備中。
(Draft: CW5 計測分析はこちらの Web）

類似度・乖離度によるクラスタリング

プログラム完成するも説明困難。事例報告不備 ϕ (..) メモメモとして。

- 事例 # 1
  - ROW：PT-Drug、COL:生データ発生期間の表（巨大）を作成、発生例数を scaling して、正規化。
  - 階層クラスターの重心を評価。
  - クラス階層数決定問題を BIC で自動設定。近代的。
- 事例 # 2
  - 基礎統計値の重心距離を対象にした上記階層・k-means のクラス分けを行う。
  - 古典的 Multi-dimensional scaling はエッジが平均化。分類能失う。
- 事例 # 3
  - LBP での輪郭把握が傾向把握に役立ちそうと確信（作成開始）
  - 二値化関数、ヒストグラム化、類似度計算（interaction）、クラス分けを書く

ここのパートは自由度が大きく、ヒトの協力により評価結果を SVM, SOM で分析。空間切って条件化。将来データにぶつけて汎用性を評価するのも「超有用（と確信）」

近接距離法による階層類似度

k-近傍法は「教師なし機械学習」の領域で最も多用される手法。重要な概念が多数存在し、どの領域も省略困難。

残念ながら、全部省略し結果だけを示す。

発生傾向変化検知の情報提供ページ参照

発生傾向変化検知の情報提供ページ にて、現在全薬剤中 80%の情報を提供しているので参照。 目を引く組み合わせを下記に示する。

CYM のある 2PT 推移の事例

CYM 分類番号 # 2 発生傾向の上昇を自動分類した事例

PRS のある 3PT 推移の事例

PRS 分類番号 # 3 発生傾向の上昇を自動分類した事例

FGT のある PT 推移の事例

FGT 分類番号 # 2 ある期間から傾向変化を自動分類した事例

人工知能はいまだ中学生レベルとされる。だが、パターン認識に於いては画像・音声認識においても機械が人をしのぐ[5]。
すばらしい。そして恐ろしい。

[5]安全性情報は「教師なし」学習である。「教師あり」には Deep Learning が凄んごい

CURRENT section

1. 異常検知 (anomaly detection) する道具の提案
2. 異常検知と自動識別の枠組み
3. パラメータ推定法
4. まとめ
5. Appendix

2nd opition 向け専門的解説

社内専門家向けに、数理的解説、検討結果を紹介する。

- BFGS 法など反復計算法
- EM 法
- MCMC 推定
  - Gibs サンプラーの JAGS 利用と結果・速度評価
  - NUT アルゴリズムの STAN 利用と結果・速度評価

反復数値計算法の概略

反復数値計算法は、微分・積分などの解を解析的に求められない場合、数値計算による近似を求める一般的枠組みをいう。
$f(x) = 0$ を求める時、収束が速いニュートン法が多用される。

$$f_{n+1} = f_n - \frac{f(x)}{f'(x)}$$

その他、黄金比探索、二本木探索など多数のアルゴリズムを問題により選択する。関数の最適化問題は計算機に対する知識も必要であり、 広範囲な専門的知識と精度良いソフトウエアが必用。
学生の勉強目的以外、素人には自作の余地がない[6]。

極値からの脱出方法などが改良された (BFGS 法など）専用ソフトの利用が推奨される。

[6]専門家の意見は総じて「数値計算なめんな！」というもの

最適化問題の制限

万能の手法は存在しない

私の見解では，最適化モデルに取り組んでいる誰もが知っていなければならない（主な）ことは，一般的に最適化問題は解けないということである。[**Kowalik**]

反復法による推定事例 I

解析センター所有の “Infinite mixuter distribution” の例 $R = 0.29, \lambda_1 = 1.10,\ \lambda_2 = 2.59$ で初期値設定の困難性を示す。

その困難以外にも、P. 26 の式 (4) が、ラベル情報が無い故の不確実な挙動も示す。

その他、定義から混合率の拘束条件設定、underflow 対策など広範囲の知識を動員して、対処した。
結果として、BFGS 法を用いても自動化が困難なことが分かった。

反復法による推定事例 II

```
> mixOPTIM <- function(thetaINIT = c(0, 1, 2), dat = DataVector) {
+     VecLogLH <- function(theta) {
+         r <- exp(theta[1])/(1 + exp(theta[1]))
+         lambda1 <- exp(theta[2])
+         lambda2 <- exp(theta[3])
+         LL <- sum(log(r * dpois(dat, lambda1) + (1 - r) * dpois(dat, lambda2)))
+         return(LL)
+     }
+     INIT <- thetaINIT
+     res <- optim(INIT, VecLogLH, method = "BFGS", hessian = TRUE, control = list(fnscale = -1))
+     return(c(exp(res$par[1])/(1 + exp(res$par[1])), exp(res$par[2]), exp(res$par[3])))
+ }
> datsample <- c(rep(0, 162), rep(1, 267), rep(2, 271), rep(3, 185), rep(4, 111), rep(5,
+     61), rep(6, 27), rep(7, 8), rep(8, 3), rep(9, 1))
> .control = "R = 0.28705, lambda1 = 1.10209, lambda2 = 2.58164, n = 1096"
> mixOPTIM(dat = datsample, thetaINIT = c(0.5, 0.4, 2))
[1] 0.36 1.26 2.66
> mixOPTIM(dat = datsample, thetaINIT = c(0.1, 0.4, 2))
[1] 0.64 2.66 1.26
> mixOPTIM(dat = datsample, thetaINIT = c(0.5, 0.4, 4))
[1]  1.00  2.16 54.60
```

反復法による推定事例 III

結果の一行目は、「答えを知っている」とすると良い推定。

結果の二行目は、ラベル問題による不確実性が再現されている。P.26 式 (4) の定義には、混合率 π がどちらに所属するか？　という情報が無い。初期値次第では λ_1, λ_2 の大小関係も変わる。これは「混合分布のラベル問題」と言われる。

この問題により $\pi, \lambda_1, \lambda_2$ 推定の大小関係が変わると、条件判断処理が複雑になり大量処理に手間がかかる。

結果の三行目は、L2 の初期値を変えるとパラメータベクトル全体が違う結果になった。

「答えを知っている」とした時でさえ、良い初期値の自動設定は困難。これらの問題から、大量の組み合わせを調べるビジネスには、 応用困難と結論づけた。

EM 法による推定 I

P.26 対数尤度関数の式 (4) に潜在変数 Z_i を与え所属情報を加える。
潜在変数は、i が第一分布に所属するとき、 1、それ以外の時 0 を示す確率変数 [**satomura**] 。
現実には測定できないこの変数は「欠測」といえるので、データは「欠測データ」と見做せる。観測できたらそのデータは「擬似完全データ」と定義する。

EM アルゴリズムは期待値算出（E-Step）と擬似完全データの最大化（M-Step) を組み合わせて、巧妙に欠測データを含むモデルの母数推定を実現する。

完全データを仮定した時の対数尤度

$$\log L(\Theta; x) = \sum_{i=1}^{n} \sum_{s=1}^{g} \left\{ Z_{is} \log(f_s(y_i \mid \theta_s; x) + Z_{is} \log \pi_s \right\}$$

π_s は、確率の要請とクラス制限が課されている。ある制限化において最適化が必用。
ラグランジュ未定乗数法を利用し、拘束条件変数 λ を含めて定式化する。

EM 法による推定 II

最適化すべき対数尤度関数

$$\log L(\Theta; x) = \sum_{i=1}^{n} \sum_{s=1}^{g} \left\{ Z_{is} \log(f_s(y_i \mid \theta_s; x) + Z_{is} \log \pi_s \right\} - \lambda(\sum_{s=1}^{g} \pi_s - 1) \tag{6}$$

(6) を最大化する 一階条件は、偏微分して得られる方程式を解けば良い。

対数尤度関数最大化一階条件

$$\frac{\partial L(\Theta)}{\partial \theta_s} = \sum_{i=1}^{n} z_{is} \frac{\log f_s(y_i \mid \theta_s; x)}{\theta_s} = 0 \tag{7}$$

$$\frac{\partial L(\Theta)}{\partial \pi_s} = \sum_{i=1}^{n} \frac{z_{is}}{\pi_{is}} - \lambda = 0 \tag{8}$$

$$\frac{\partial L(\Theta)}{\partial \lambda} = -\sum_{s=1}^{g} \pi_s + 1 = 0 \tag{9}$$

上記の連立方程式を解く。(8)、(9) より $\lambda = n$、$\pi_s = \sum_{i=1}^{n} \frac{z_{is}}{n}$ を得る。

EM 法による推定 III

(7) より λ_1、λ_2 を得る。
各 λ_1、λ_2 の時、クラス事後確率は P. 32 の (5) より得られ、クラス情報になる。

E-step、M-step の方程式が導出できれば勾配法、反復法などで解ける。素晴らしい。

鋭い方から、「解析的に解けないといったじゃないか！」とツッコミがありそうだが、擬似完全情報を仮定するアイディアにより解析的に解けるのである。21 世紀の 10 大アルゴリズムとも言われ、開発者の素晴らしさに感謝して自分のビジネスに生かす。

EM の実装現場利用 I

GitHUB に公開（予定）したプログラム実装例の性能確認を行う。混合分布の乱数を発生させる関数を作成し、推定プログラムを検証する。

混合割合 $\pi = 0.7$, 第一平均 $\lambda_1 = 0.2$、第二平均 $\lambda_2 = 5$ で乱数を発生させて、推定結果と比較する。

EM の実装現場利用 II

```
> dat <- makeMixtureDF(n = 100, r = 0.7, lambda1 = 0.2, lambda2 = 5)
> estimateMixturePoison(dat$y, debugprint = T)
r = 0.70, L1Mstep = 0.173, L2Mstep = 5.350 , CNT(001:eps 86.2379932812)
r = 0.70, L1Mstep = 0.187, L2Mstep = 5.324 , CNT(002:eps 0.0522192974)
r = 0.70, L1Mstep = 0.190, L2Mstep = 5.338 , CNT(003:eps 0.0039624295)
r = 0.70, L1Mstep = 0.191, L2Mstep = 5.346 , CNT(004:eps 0.0007005639)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.349 , CNT(005:eps 0.0001255624)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.350 , CNT(006:eps 0.0000224780)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(007:eps 0.0000040217)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(008:eps 0.0000007194)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(009:eps 0.0000001287)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(010:eps 0.0000000230)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(011:eps 0.0000000041)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(012:eps 0.0000000007)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(013:eps 0.0000000001)
r = 0.70, L1Mstep = 0.192, L2Mstep = 5.351 , CNT(014:eps 0.0000000000)
$R
[1] 0.702

$Lambda1
[1] 0.192

$Lambda2
[1] 5.35
> dat$txt
[1] "R = 0.7,  Lambda1 = 0.2, Lambda2 = 5.0, N = 100"
```

EM の実装現場利用 III

サンプルサイズ $n = 100$ は、約８年間の安全性情報を対象として想定。収束条件は、尤度差 $\leq 10^{-10}$ とした。事例は 14 回で条件を満たした。

推定値は、$\pi = 0.702$, 平均 $\lambda_1 = 0.192$、$\lambda_2 = 5.35$ と仮想データ $(\pi = 0.7, \lambda_1 = 0.2, \lambda_2 = 5)$ に近い値を示した。

この枠組みで DB 内の複雑な事例に対し、機械的に傾向把握できる可能性がある。ビジネス応用の場面で、この推定結果が役立つだろう。

専門知識なしでデータから学習する「**機械学習の現場利用**」である。

MCMC 推定 I

NEC 製スパコンが GFLOPS の壁を超えたのは、1980 年前半。

パーソナルコンピュータの性能向上は著しく、居室 PC でも 30GFLOPS 程度の性能を持つ。性能向上著しい PC を用いてシミュレーション統計を行うのが MCMC である。かつては専門家が、数学的知識、工学的知識、プログラミングを駆使して実施した。

2013 年ごろ、高名な米国統計家集団が、数億円規模の米国政府予算を利用し、収束効率のよい MCMC 法を実装した「stan」が公開されライセンスフリーで利用できる。

より「実行が早く、マルチコア化のメリット」な Open Source。

なお、source は qiita.com の報告データの統計解析で公開中。

MCMC 推定 II

```
> fit <- sampling(modelPoiMixturePosOrd, data=list(y=datsample, N=length(datsample)) ,
+                  iter = 5000,show_messages = F,
+                open_progress =F, chains =4 , verbose = F)
starting worker pid=9084 on localhost:11637 at 16:58:22.715
（すこし省略）
Chain 4, Iteration: 5000 / 5000 [100%]  (Sampling)
 Elapsed Time: 47.473 seconds (Warm-up)
               55.413 seconds (Sampling)
               102.886 seconds (Total)

> fit
Inference for Stan model: 3acaa4497464a6caf58c47e8ee754de9.
4 chains, each with iter=5000; warmup=2500; thin=1;
post-warmup draws per chain=2500, total post-warmup draws=10000.

              mean se_mean   sd     2.5%      25%      50%      75%    97.5% n_eff Rhat
R             0.41    0.01 0.18     0.11     0.27     0.39     0.54     0.80  1283    1
lambda[1]     1.30    0.01 0.33     0.58     1.09     1.34     1.54     1.86  1136    1
lambda[2]     2.75    0.01 0.31     2.34     2.54     2.69     2.90     3.52  1191    1

Samples were drawn using NUTS(diag_e) at Mon Sep 12 17:00:09 2016.
For each parameter, n_eff is a crude measure of effective sample size,
and Rhat is the potential scale reduction factor on split chains (at
convergence, Rhat=1).

> estimateMixturePoison(datsample)
R
[1] 0.359
Lambda1
[1] 1.25
Lambda2
[1] 2.66
```

MCMC 推定 III

解析センター所有の教科書"Infinite mixuter distribution"の例で検証。
$R = 0.29, \lambda_1 = 1.10,\ \lambda_2 = 2.59$ が推定すべきパラメータ

1 万サンプルを空回しで破棄し。2 万回（5000×4chain）サンプルでの推定値は、
$R = 0.41, \lambda_1 = 1.30,\ \lambda_2 = 2.75$ という結果。

EM 法で推定した結果は、
$R = 0.36, \lambda_1 = 1.25,\ \lambda_2 = 2.66$ という結果。

[**toyota**] は、「経験的に MCMC 推定は数万回シミュレーションで小数点２，３桁の精度が得られる。これは１%程度の精度であり、実用上問題は無い。数百万回シミュレーションも可能だが一般実務では不要だろう」と述べている。

今回の MCMC の計算時間は約 103 秒であり、データベース内の全組み（6905）を対象にした場合、10 日程度の計算資源 が必用と分かった。

CURRENT section

1. 異常検知 (anomaly detection) する道具の提案
2. 異常検知と自動識別の枠組み
3. パラメータ推定法
4. まとめ
5. Appendix

性能確認のまとめ

反復法は初期値により推定結果が異なる場合がある。ヒトがデータを確認し、初期値設定する必要がある。手間が必用で、自動化に不向きだった。

MCMC は深い？ 数学的知識は不要で、モデルの乱数が定義できる統計やプログラム知識があればよい。その代償に、原理的に莫大な計算時間を要する。時間・PC 資源管理が重要であり、効率的な利用は困難と判断した。

EM 法は、指数分布の推定では理論的に収束が確実である [**watanabe**]。高速に収束する点も業務向きであり、この手法を主に利用することとした。

異常検知のまとめ

累積 XX 例で・・・という手順は網羅的であるが、未知例対象。つまり、ある事例に特化した手順に過ぎない。
不定期である。STOP 条件がないので終わりがない。しかも約 9000 もの評価対象が控えている。 作業の効率化が必要とされている。

今後の異常検知を改善 point

- 「件数」から脱却して、**不確定性を「確率」**で測定すると良い
- 「集まったら」から脱却して、**定期的な評価**に転換すれば良い

関係者に結果を確認してもらい、評価を頂きたい。
この提案が新しい情報の発見・効率化に貢献でき、対応が成されることを確信~~して~~願っている。

$$
\begin{aligned}
f(\text{機械} \mid \text{学習する}) &= \lim_{x \to \infty} \text{初期値} \times 1.001^x &= \infty \\
f(\text{私} \mid \text{学習しない}) &= \lim_{x \to \infty} \text{初期値} \times 0.999^x &= 0
\end{aligned}
$$

学習する機械 $\gg$ 学習しない私

提案のおわり

I hope you like it!

第三部[7] 完

[7]第四部につづく

今後に予定する提案（第四部以後）

1. 専門知識なし・教師なし学習
   1.1 **近代的因果推論**
   - スコア検定[8]による因果推論
   - S.E.M, Naive bayes

   1.2 **確率過程の利用**
   - マルコフ性の利用
   - 状態が関係するモノへの取り組み（夏「光線過敏症」、RAC 季節性）

   1.3 **状態空間モデル**
   - 「状態」と「観測」を分けてモデル化し、「欲しい「状態」」を推論する
   - 患者数「状態」は観測できず、報告数のみ「観測」される
   - マルコフ性、季節性、回帰の全てを組み入れたモデルが利用可能
2. 専門知識あり・教師あり学習
   2.1 **アンサンブル学習**
   - Deep learning, Nerural network
   - Randomforest, boosting, S.V.M, Bagging

   2.2 **新薬「では」報告されなかった事象への応用**
   - 市販後データから得た知識を事前情報とし、事後確率を更新（ベイズ更新）

近代的情報理論を利用し、意思決定支援! その実現を目指せ！

[8] RCT 困難な事例に調査データで対応する

わたしの戦闘力は530000000です
ですがもちろんフルパワーであなたと闘う気はありませんからご心配なく…

わたしの戦闘力は530000000です
ですがもちろんフルパワーであなたと闘う気はありませんからご心配なく…

このフリーザは変身をするたびにパワーがはるかに増す…
その変身をあと2回もオレは残している…
その意味がわかるな？

荀子:じゅんし儒效、B.C 313 年? - B.C 238 年以降

聞かざるは之を聞くに若かず。
之を聞くは之を見るに若かず。
之を見るは之を知るに若かず。
之を知るは之を行うに若かず。
学は之を行うに至たりて止む。

CURRENT section

1. 異常検知 (anomaly detection) する道具の提案
2. 異常検知と自動識別の枠組み
3. パラメータ推定法
4. まとめ
5. Appendix

References I

- 高校数学の美しい物語, マスオ, 2016
- Categorical Data Analysis. Wiley Series in Probability and Statistics, third edition., Alan Agresti, 2013
- Discrete Data Analysis with R, Friendly M and Meyer D, 2016
- 稀な事象の生起確率に関する統計的推測 -Rule of Three とその周辺-, 岩崎 学 and 吉田 清隆, 2005
- ゼロ修正されたポアソン分布におけるゼロ修正パラメータの統計的推測, 岩崎 学 and 大道寺 香澄, 2013
- 社内データベース CW5 内情報分析事例について, 山口 学, 社内資料, 2016
- マーケティングモデル, 里村 卓也, 2015, 共立出版
- Bayesian Modelling and Inference On Mixtures of Distributions, Jean Michel Marin and Kerrie Mengersen, Paris Univ, 2010
- 統計計算の展開と統計科学　第 III 部, 渡辺 美智子, 統計科学会, 2008

References II

- Methods for Uncon-strained Optimization Problems, Kowalik, J. and Osborne, M., Elsevier, 1968
- マーケティングモデル, 里村 卓也, 共立出版, 2015
- 基礎からのベイズ統計学（ハミルトニアンモンテカルロ法による実践的入門）, 豊田 秀樹, 朝倉書店, 2015